Odbiory prac statutowych 2025

Barbara Żogała-Siudem
IBS PAN

19.12.2025

Prace w recenzji lub przygotowaniu

1. Brzozowski, Ł., Gagolewski, M., Siudem, G., Żogała-Siudem, B. *The Price–Pareto growth model of networks with community structure*, (w recenzji)
2. Petelczyc, M., Żogała-Siudem, B., Teichert, D., Bruhn, S., Weippert, M., *Effects of breathing patterns on heart rate variability during exercise*, (w przygotowaniu)

Dlaczego zajęliśmy się tym problemem?

- Nasz model 3DSI bardzo dobrze dopasowuje się do rozkładów stopni wierzchołków w rzeczywistych sieciach (np. sieci cytowań) ...
- ... ale nie dawał możliwości uwzględnienia społeczności, powszechnie obserwowanych w tych grafach.
- Z drugiej strony znane w literaturze modele społeczności (np. Stochastic Block Model) odtwarzają podział grafu na klastry ...
- ... ale błędnie przewidują rozkłady stopni wierzchołków.

Wniosek

Zmodyfikowaliśmy model 3DSI, tak, aby odtwarzał **nie tylko** rozkład stopni wierzchołków, ale także **strukturę społeczną** grafu.

Dlaczego zajęliśmy się tym problemem?

- Nasz model 3DSI bardzo dobrze dopasowuje się do rozkładów stopni wierzchołków w rzeczywistych sieciach (np. sieci cytowań) ...
- ... ale nie dawał możliwości uwzględnienia społeczności, powszechnie obserwowanych w tych grafach.
- Z drugiej strony znane w literaturze modele społeczności (np. Stochastic Block Model) odtwarzają podział grafu na klastry ...
- ... ale błędnie przewidują rozkłady stopni wierzchołków.

Wniosek

Zmodyfikowaliśmy model 3DSI, tak, aby odtwarzał **nie tylko** rozkład stopni wierzchołków, ale także **strukturę społeczną** grafu.

Dlaczego zajęliśmy się tym problemem?

- Nasz model 3DSI bardzo dobrze dopasowuje się do rozkładów stopni wierzchołków w rzeczywistych sieciach (np. sieci cytowań) ...
- ... ale nie dawał możliwości uwzględnienia społeczności, powszechnie obserwowanych w tych grafach.
- Z drugiej strony znane w literaturze modele społeczności (np. Stochastic Block Model) odtwarzają podział grafu na klastry ...
- ... ale błędnie przewidują rozkłady stopni wierzchołków.

Wniosek

Zmodyfikowaliśmy model 3DSI, tak, aby odtwarzał **nie tylko** rozkład stopni wierzchołków, ale także **strukturę społeczną** grafu.

Model Price-Pareto bez skupień – 3DSI

Cel: Budowa grafu o N wierzchołkach

Otrzymujemy: rozkład stopni wierzchołków

Model: iteracyjny

Parametry:
- m - liczba dokładanych krawędzi w danym kroku
- ρ - stopień „preferencyjności"

W każdej iteracji:

1. Dokładamy nowy wierzchołek v, który łączy się m krawędziami z już istniejącymi wierzchołkami w grafie.
2. Najpierw $(1-\rho)m$ krawędzi, wychodzących z v zostaje przypisanych losowo do istniejących już wierzchołków.
3. Następnie ρm krawędzi zostaje dołączonych preferencyjnie – z prawdopodobieństwem proporcjonalnym do stopni wierzchołków.

Model Price-Pareto bez skupień – 3DSI

Cel: Budowa grafu o N wierzchołkach

Otrzymujemy: rozkład stopni wierzchołków

Model: iteracyjny

Parametry:
- m - liczba dokładanych krawędzi w danym kroku
- ρ - stopień „preferencyjności"

W każdej iteracji:

1. Dokładamy nowy wierzchołek v, który łączy się m krawędziami z już istniejącymi wierzchołkami w grafie.
2. Najpierw $(1-\rho)m$ krawędzi, wychodzących z v zostaje przypisanych losowo do istniejących już wierzchołków.
3. Następnie ρm krawędzi zostaje dołączonych preferencyjnie – z prawdopodobieństwem proporcjonalnym do stopni wierzchołków.

Model Price-Pareto bez skupień

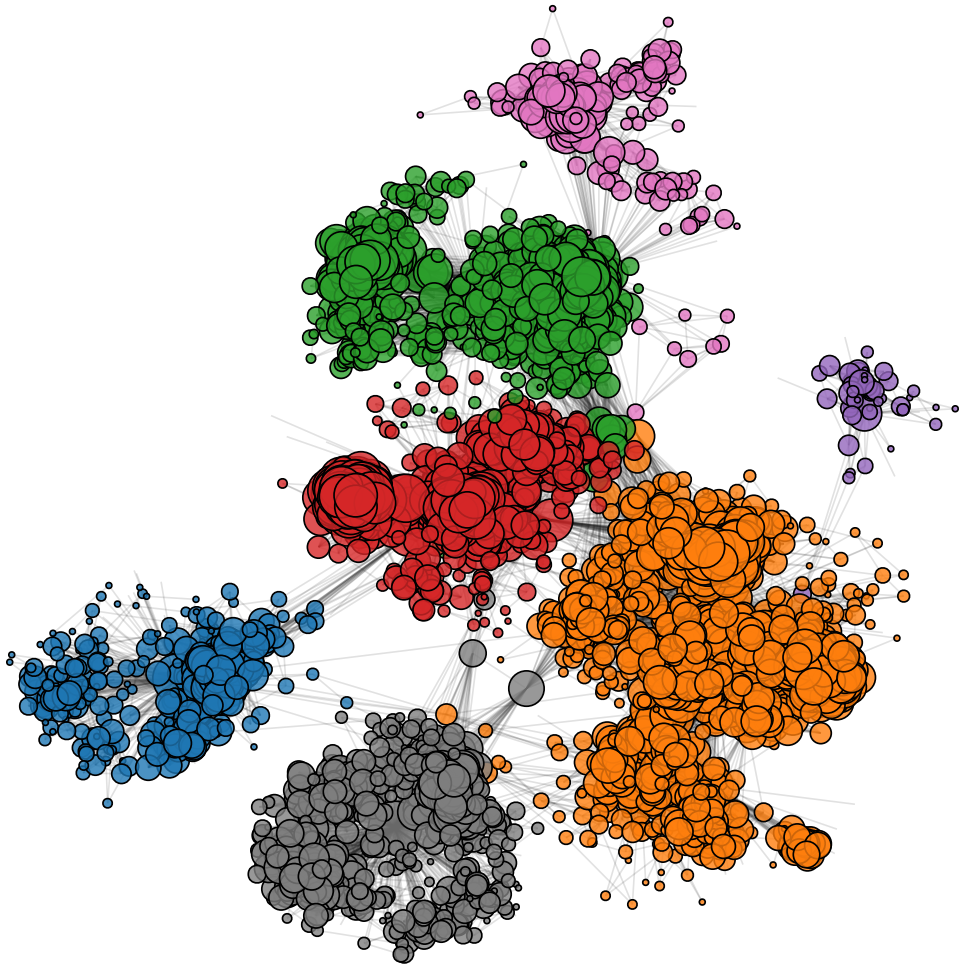
Rozkład stopni wierzchołków – zależność rekurencyjna

$$\underbrace{d^{(t)}(\ell)}_{\substack{\text{the degree of node } \ell \\ \text{in turn } t}} = \underbrace{d^{(t-1)}(\ell)}_{\substack{\text{the degree of node } \ell \\ \text{in turn } t-1}} + \underbrace{\overset{(t)}{\mathrm{Acc}}(\ell)}_{\text{accidental income}} + \underbrace{\rho m \frac{d^{(t-1)}(\ell) + \mathrm{Acc}^{(t)}(\ell)}{(t-1)m + (1-\rho)m}}_{\text{preferential income}}.$$

Rozkład stopni wierzchołków - gotowy graf

$$d(\ell) = \frac{m(1-\rho)}{\rho}\left(\frac{\Gamma(\ell-\rho)\Gamma(N+1)}{\Gamma(\ell)\Gamma(N+1-\rho)} - 1\right).$$

Graf ze strukturą skupień (facebook graph, Stanford data)



Graf ze strukturą skupień

Założenia:

- N wierzchołków, k skupień o licznościach $Np_1, \ldots, Np_k$.
- Każde skupienie ma swoje parametry m_i oraz ρ_i.
- Krawędzie przypadkowe są rozdawane wśród wierzchołków w całym grafie.
- Krawędzie preferencyjne są rozdawane w ramach skupienia.

Iteracje:

1. Nowemu wierzchołkowi v zostaje przydzielone skupienie i z prawdopodobieństwem p_i.
2. Losowane są przypadkowe krawędzie (sąsiedzi) v spośród wszystkich wierzchołków w grafie.
3. Losowane są preferencyjne krawędzie - spośród wierzchołków znajdujących się w skupieniu i.

Graf ze strukturą skupień

Założenia:

- N wierzchołków, k skupień o licznościach $Np_1, \ldots, Np_k$.
- Każde skupienie ma swoje parametry m_i oraz ρ_i.
- Krawędzie przypadkowe są rozdawane wśród wierzchołków w całym grafie.
- Krawędzie preferencyjne są rozdawane w ramach skupienia.

Iteracje:

1. Nowemu wierzchołkowi v zostaje przydzielone skupienie i z prawdopodobieństwem p_i.
2. Losowane są przypadkowe krawędzie (sąsiedzi) v spośród wszystkich wierzchołków w grafie.
3. Losowane są preferencyjne krawędzie - spośród wierzchołków znajdujących się w skupieniu i.

Graf ze strukturą skupień

Rozkład stopni wierzchołków - zależność rekurencyjna

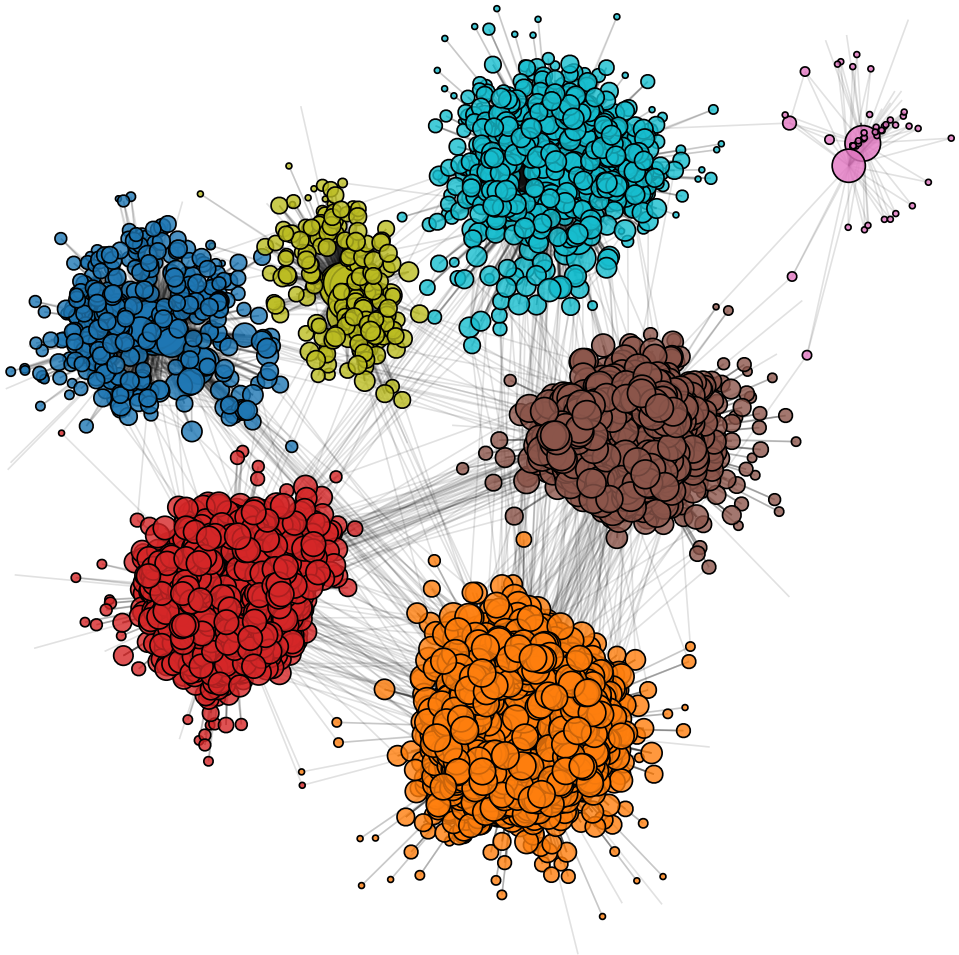
$$\underbrace{d_i^{(t)}(\ell)}_{\substack{\text{the in-degree}\\ \text{of node } \ell\\ \text{in cluster } i\\ \text{in (local) turn } t}} = \underbrace{d_i^{(t-1)}(\ell)}_{\substack{\text{the in-degree}\\ \text{in the previous}\\ \text{turn}}} + \underbrace{\mathrm{Acc}_i^{(t)}(\ell)}_{\substack{\text{accidental}\\ \text{income}}} + \underbrace{\rho_i m_i \frac{d_i^{(t-1)}(\ell) + \mathrm{Acc}_i^{(t)}(\ell)}{\sum_{r=1}^{t-1}\left[d_i^{(t-1)}(r) + \mathrm{Acc}_i^{(t-1)}(r)\right]}}_{\text{preferential income}}$$

Rozkład stopni wierzchołków - gotowy graf

$$d_i^{(t)}(\ell) = \frac{\langle a\rangle}{\nu_i}\left[\frac{\Gamma(\ell-\nu_i)}{\Gamma(\ell)}\frac{\Gamma(t)}{\Gamma(t-\nu_i)} - 1\right],$$

gdzie $\nu_i = 1 - \frac{\langle a\rangle}{\langle a\rangle+\rho_i m_i} = \frac{\rho_i m_i}{\langle a\rangle+\rho_i m_i}$ oraz $\langle a\rangle = \sum_{j=1}^{k} p_j m_j - \sum_{j=1}^{k} p_j m_j \rho_j$

Wygenerowany graf



Estymowanie parametrów modelu

Parametry

p_i - pstwa przynależności do klastra

m_i - średni stopień wierzchołka w klastrze

ρ_i - stopień losowości

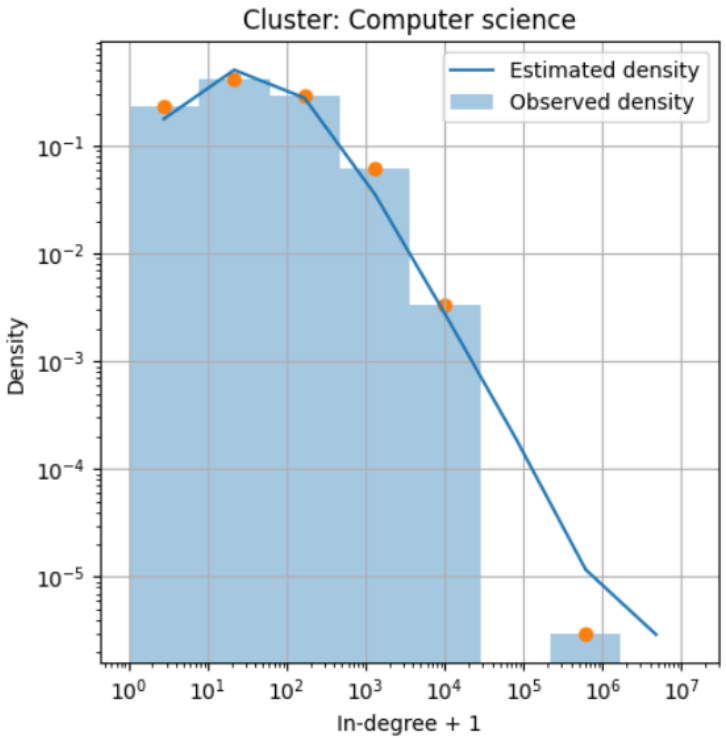
Estymacja

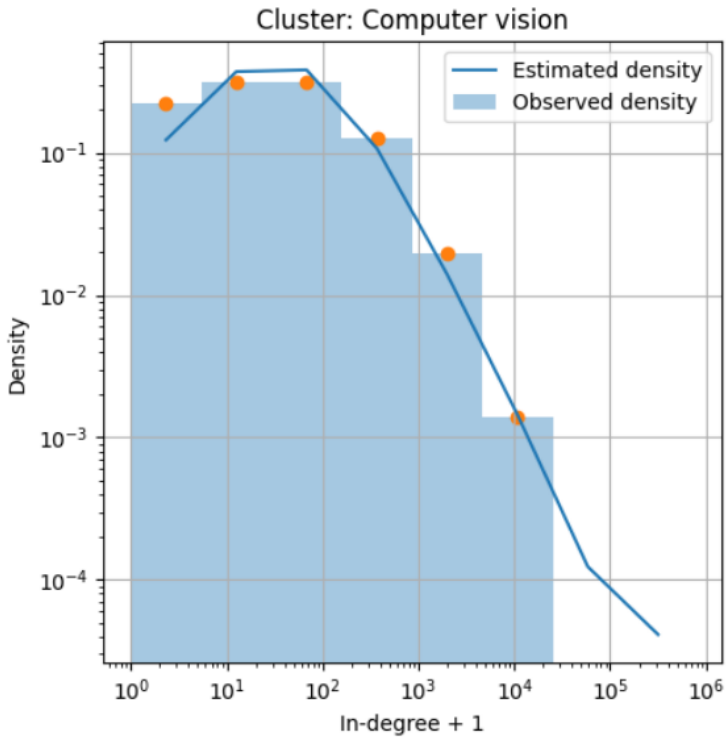
$\hat{p}_i = \frac{N}{N_i}$

$\hat{m}_i$ - średni stopień wierzchołka w klastrze

$\hat{\rho}_i$ - estymacja basująca na indeksie Giniego rozkładu stopni wierzchołków w klastrze

Rozkłady stopni wierzchołków w skupieniach - baza DBLP





Dziękuję za uwagę!